Proyecto Final

Diplomatura en Ciencia de Datos y Análisis Avanzado

Desempeño sanitario y utilización de recursos críticos durante la pandemia de COVID-19 en Argentina: un análisis comparativo sectorial y territorial

Grupo 7

Integrantes:

Sebastian Vera | Jessica Marcela Kaufman | Matias Lercari | Juan Pablo Villareal Nuñez

1. Resumen ejecutivo

Ante la aparición de una nueva variante de COVID-19, el Ministerio de Salud enfrenta nuevamente el desafío de anticipar tensiones en el sistema sanitario y optimizar decisiones de gestión. En este contexto, los registros históricos del SISA constituyen la única fuente integrada, homogénea y disponible de alcance nacional que permite reconstruir patrones epidemiológicos, clínicos y de utilización de recursos durante la pandemia.

La crisis sanitaria evidenció presiones asistenciales desiguales entre jurisdicciones, heterogeneidad en la utilización de recursos críticos (internación, cuidados intensivos (UCI) y asistencia respiratoria mecánica (ARM)) y variaciones relevantes en los desenlaces clínicos observados. Sin embargo, la ausencia de métricas unificadas y comparables de desempeño sanitario ajustadas por severidad y perfil demográfico limita la capacidad de identificar qué provincias y qué sector del sistema de salud mostraron una respuesta más eficiente.

El presente proyecto propone desarrollar un marco analítico que combine análisis descriptivo, técnicas de segmentación no supervisadas (clustering) y modelado supervisado. El objetivo es construir indicadores de desempeño sanitario comparables entre provincias, sector y provincias por sector, evaluar diferencias estructurales y analizar la estabilidad de dichos patrones en el tiempo.

La estrategia de modelado incorpora una comparación explícita entre un modelo global ajustado y modelos segmentados por sector (público/privado) y por período epidemiológico (baja, media y alta intensidad), con el fin de evaluar si los determinantes de mortalidad se

comportan de manera homogénea o presentan variaciones según el contexto. Asimismo, se busca habilitar la simulación de escenarios epidemiológicos basados en configuraciones históricas, con potencial utilidad para la planificación estratégica.

Los KPIs estratégicos de impacto esperado son: 1) Mortalidad entre internados; 2) Mortalidad en UCI; 3) Mortalidad en ARM; 4) Mortalidad hospitalaria estratificada por edad; y 5) Mortalidad de internados en periodos de alta intensidad.

Los resultados están dirigidos a autoridades sanitarias, gestores hospitalarios y equipos de planificación, aportando insumos cuantitativos para el benchmarking territorial, la evaluación de desempeño relativo y la toma de decisiones en contextos de emergencia sanitaria.

2. Definición del problema y caso de negocio

2.1. Problema, objetivos e hipótesis

La inexistencia de un análisis integrado de desempeño sanitario territorial y sectorial impide responder preguntas clave para la planificación ante eventos epidémicos futuros. Entre ellas, resulta clave comprender si existieron diferencias sistemáticas en la mortalidad hospitalaria bajo condiciones comparables de severidad, si dichas diferencias se manifestaron entre sectores del sistema de salud y cómo variaron durante períodos de mayor demanda asistencial.

Durante la pandemia, la comparación directa entre provincias resultó metodológicamente compleja debido, entre otros aspectos, a diferencias en la estructura etaria de los pacientes, en la severidad de los casos atendidos y en la intensidad epidemiológica de cada período. En ausencia de indicadores ajustados, la interpretación de resultados brutos puede inducir conclusiones sesgadas.

El proyecto se propone, como objetivo general, reconstruir y analizar indicadores de desempeño sanitario comparables entre provincias y sectores del sistema de salud argentino, utilizando registros históricos de COVID-19. Los objetivos específicos son:

1. Estimar KPIs de desempeño sanitario ajustados por severidad y edad.
2. Identificar perfiles estructurales mediante clustering.
3. Evaluar diferencias sistemáticas mediante modelado supervisado comparativo (global vs. segmentado).

4. Analizar estabilidad y variación temporal del desempeño.

Las hipótesis que orientan el análisis parten de la premisa de que el desempeño sanitario no fue homogéneo según provincia, sector y provincia×sector:

- **H1 (Severidad).** Difiere la mortalidad estratificada por nivel de severidad (internación, UCI, ARM).
- **H2 (Edad).** Difiere la mortalidad hospitalaria dentro de estratos etarios.
- **H3 (Dinámica temporal).** El desempeño sanitario relativo presenta variaciones temporales con periodos de baja, mediana y alta intensidad.
- **H4 (Modelo supervisado).** Aun controlando por edad y severidad, persisten diferencias sistemáticas de mortalidad.

2.3. Restricciones y valor esperado

El análisis se desarrolla bajo limitaciones inherentes a la fuente de datos. El dataset no incorpora información sobre comorbilidades clínicas, lo que introduce posibles factores de confusión residual. Tampoco se dispone de datos dinámicos de disponibilidad de camas, por lo que la presión asistencial deberá inferirse indirectamente. Adicionalmente, se reconoce la existencia potencial de demoras o subregistros en la carga de fechas, junto con heterogeneidad en la calidad de carga territorial.

Se espera que el proyecto contribuya al benchmarking sanitario territorial, a la identificación de jurisdicciones relativamente resilientes, al soporte analítico para la planificación de recursos críticos y a la evaluación de sensibilidad del sistema ante escenarios epidémicos simulados.

3. Relevamiento de fuentes de datos y consideraciones éticas

3.1. Fuente y decisiones de limpieza

La fuente utilizada corresponde a los registros oficiales del Ministerio de Salud de la República Argentina (SISA), disponibles como dataset público en el portal Datos Argentina. Se trata de datos estructurados en formato tabular (.csv), que contienen información demográfica, clínica, sectorial y temporal de los casos registrados durante la pandemia. El dataset original comprende 29.971.992 registros, 25 columnas y un volumen cercano a 6 GB.

El procesamiento inicial se realizó en una etapa de limpieza independiente, previa al análisis, con el objetivo de reducir el volumen de datos y garantizar que únicamente los registros con

impacto real en el sistema sanitario formaran parte del trabajo. En primer lugar, se eliminaron todos los casos con resultado negativo, reteniendo exclusivamente los casos confirmados de COVID-19. En segundo lugar, dentro de los casos confirmados, se descartaron aquellos que no registraron internación, dado que el proyecto busca evaluar la performance del sistema hospitalario y los casos ambulatorios no son relevantes para ese fin. Este proceso se ejecutó en un entorno de trabajo separado del análisis principal, preservando el orden y la trazabilidad del pipeline. Como resultado, el dataset original quedó reducido a aproximadamente 237.000 registros y 27 MB, lo que además permitió trabajar con los modelos de forma significativamente más eficiente.

Las variables seleccionadas para el análisis abarcan dimensiones demográficas (principalmente edad), geográficas (provincia de residencia), sectoriales (origen de financiamiento), clínicas/severidad (internación, cuidados intensivos, ARM), desenlace (fallecimiento) y temporales (fechas clave del proceso asistencial).

Sobre el dataset resultante se aplicaron decisiones adicionales de limpieza y estandarización: imputación de edad mediante la mediana, conversión forzada de fechas a formato datetime, filtrado de outliers biológicamente inconsistentes (edad > 110) y eliminación de columnas administrativas o redundantes.

Se definió un diccionario mínimo de variables clave utilizadas en el modelado:

Variable	Descripción
edad	Variable demográfica central para ajuste de riesgo
residencia_provincia_nombre	Unidad territorial de análisis
origen_financiamiento	Clasificación sectorial público/privado
internado_bin	Proxy de severidad (1 si tiene fecha de internación)
cuidado_intensivo_bin	Indicador de ingreso a UCI
asistencia_respiratoria_mecanica_bin	Indicador de soporte ventilatorio
fallecido_bin	Variable outcome (1 = fallecido)
fecha_apertura	Referencia temporal epidemiológica

fecha_internacion	Evento asistencial
intensidad_epidémica	Clasificación mensual: Alta / Media / Baja (construida)
severidad_ordinal	Escala 0–3 combinando internación + UCI + ARM (construida)
provincia_sector	Variable combinada provincia × sector (construida)

Las variables derivadas intensidad_epidémica, severidad_ordinal y provincia_sector fueron construidas durante la etapa de feature engineering. La intensidad epidémica se clasifica por mes según umbrales estadísticos (media ± 1 desviación estándar de la mortalidad mensual). La severidad ordinal combina en una escala de 0 a 3 los niveles de escalada clínica: internado sin UCI ni ARM (0), con UCI (1), con ARM sin UCI (2) y con UCI y ARM (3).

3.2. Consideraciones éticas

El proyecto utiliza exclusivamente datos anonimizados, garantizando la imposibilidad de reidentificación. El análisis se enfoca estrictamente en la evaluación sistémica del desempeño sanitario, evitando inferencias sobre desempeño individual o profesional. Las comparaciones sectoriales y territoriales serán interpretadas con cautela, reconociendo la influencia de factores estructurales y sesgos de registro.

4. Plan de modelado y validación

La estrategia analítica combina enfoques no supervisados y supervisados con el objetivo de transformar datos históricos en conocimiento accionable sobre desempeño sanitario. El plan incorpora una comparación explícita entre un modelo global y modelos segmentados, permitiendo evaluar si los determinantes de mortalidad se comportan de manera homogénea o presentan variaciones según sector y período epidemiológico.

4.1. Enfoque no supervisado: Clustering

Para el análisis de clustering se realizaron segmentaciones independientes por provincia, por sector y por combinaciones provincia×sector, con el objetivo de identificar perfiles estructurales de desempeño sanitario. Su función es descriptiva y exploratoria: agrupa jurisdicciones según la similitud de sus KPIs sin predecir ningún outcome individual. La pregunta que responde es: ¿existen grupos naturales de jurisdicciones con comportamiento sanitario similar?

Las variables fueron estandarizadas mediante StandardScaler previo al clustering, garantizando que ningún KPI domine por escala. El set de variables de entrada es más amplio que la mortalidad simple e incorpora múltiples dimensiones del desempeño hospitalario: tasas de mortalidad general, en UCI, en ARM y entre pacientes sin UCI; tasas de utilización de recursos críticos (UCI, ARM, casos severos); y tiempos de respuesta del sistema (días síntomas a diagnóstico, apertura a internación e internación a UCI). Esta combinación permite que el clustering capture tanto la severidad de los desenlaces como la velocidad de respuesta del sistema, ofreciendo una caracterización más completa de cada jurisdicción.

Se evaluaron dos algoritmos de forma comparativa: KMeans y clustering jerárquico aglomerativo. El número óptimo de clusters se determinó mediante el método del codo combinado con el Silhouette Score.

4.2. Enfoque supervisado: Modelado comparativo de mortalidad

Se emplean modelos de regresión logística orientados a modelar la probabilidad de fallecimiento a nivel de paciente individual. Estos modelos no están destinados a la predicción clínica individual, sino a la evaluación explicativa de asociaciones estructurales entre edad, severidad, sector y provincia, y a la comparación sistemática entre segmentos. La métrica principal es el AUC-ROC, adecuada para outcomes binarios con desbalance de clases.

4.2.1. Modelo Global Ajustado (baseline)

Se estima un único modelo de regresión logística con la totalidad de los datos, incluyendo las siguientes covariables: edad, severidad (internado_bin, cuidado_intensivo_bin, asistencia_respiratoria_mecanica_bin), provincia de residencia (variables dummy) y sector del sistema de salud (origen_financiamiento). Este modelo cumple la función de baseline nacional y sirve como referencia para comparar los modelos segmentados.

4.2.2. Modelos Segmentados

Se estiman modelos independientes para cada segmento de interés, manteniendo la misma especificación de variables que el modelo global. Se proponen dos segmentaciones:

Segmentación	Modelo 1	Modelo 2	Hipótesis evaluada
Por sector	Sector Público	Sector Privado	H1/H4: ¿difieren los determinantes según financiamiento?
Por período epidemiológico	Baja, Media y Alta Intensidad		H3: ¿cambia la mortalidad bajo presión asistencial?

4.3. Articulación entre clustering y modelado supervisado

Clustering y regresión logística responden preguntas distintas y se complementan metodológicamente:

Componente	Función	Pregunta que responde
Clustering (KMeans + clustering jerárquico)	Descriptiva / exploratoria	¿Qué grupos naturales de provincias existen según su perfil de mortalidad?
Regresión logística global	Explicativa (baseline)	¿Qué factores explican la mortalidad a nivel nacional?
Regresión logística segmentada	Comparativa / confirmatoria	¿Esos factores se comportan igual en todos los segmentos?

En la práctica, los perfiles identificados por el clustering pueden incorporarse como variable explicativa en la regresión logística. En lugar de incluir las 24 provincias individualmente, se puede utilizar el cluster al que pertenece cada provincia, reduciendo la dimensionalidad del modelo y facilitando la interpretación de los coeficientes.

4.4. Criterios de evaluación y umbrales de valor analítico

Se considerará que el modelado aporta valor analítico bajo los siguientes criterios:

- Clustering: Silhouette Score aceptable (>0.3) y clusters interpretables bajo variaciones razonables del número de grupos. Se compararán KMeans y clustering jerárquico reportando inercia y Silhouette Score para cada algoritmo.
- Modelos supervisados: AUC-ROC consistentemente superior a 0.75 en todos los segmentos, indicando capacidad discriminativa significativa.

- Comparación entre modelos: diferencias observables en AUC-ROC o en la magnitud de coeficientes entre el modelo global y los segmentados, que permitan concluir sobre la heterogeneidad de los determinantes de mortalidad.

El desempeño relativo de cada provincia o sector se interpretará en función de benchmarks internos construidos como promedios nacionales ponderados por volumen de casos, permitiendo clasificar el desempeño sanitario en términos de comportamiento observado versus esperado.

5. Resultados y hallazgos

5.1. Benchmark nacional

KPIs Principales — COVID-19 Internados Argentina

Total internados	Tasa de mortalidad	Requirieron UCI	Edad promedio
236,856	33.8%	20.9%	58.2 años
Mar 2020 – Jun 2022	80,037 fallecidos	49,435 pacientes	rango 0 – 109

El dataset final comprende 236.856 pacientes internados por COVID-19 en Argentina entre marzo de 2020 y junio de 2022, con una edad promedio de 58,2 años y un rango de 0 a 109 años. La tasa de mortalidad hospitalaria fue del 33,8%, equivalente a 80.037 fallecidos, lo que refleja la severidad intrínseca de la población analizada (exclusivamente pacientes que requirieron internación). El 20,9% de los internados (49.435 pacientes) requirió cuidados intensivos (UCI), evidenciando que una porción significativa de los casos presentó escalada clínica grave. Como se detalla en la sección metodológica, estos indicadores no deben interpretarse como mortalidad poblacional por COVID-19, sino como métricas de desempeño dentro del sistema hospitalario, que es el ámbito de análisis del presente proyecto.

5.2. Perfil descriptivo de los internados

El dataset analizado comprende 236.856 pacientes internados por COVID-19 en Argentina entre marzo de 2020 y junio de 2022, con una edad promedio de 58.2 años y un rango de 0 a 109 años. En términos de composición etaria, el grupo más numeroso fue el de adultos jóvenes (31-60 años) con el 39% de los internados, seguido por adultos (61-80 años) con el 34.4%. Los grupos de mayor edad concentraron la mayor mortalidad: ancianos (91+) con

67.5% y adultos mayores (81-90) con 60.7%, mientras que los grupos más jóvenes presentaron tasas significativamente menores, por debajo del 5%.

En cuanto a la distribución sectorial, el 65% de las internaciones correspondió al sistema público (153.990 pacientes) y el 35% al privado (82.866 pacientes). La distribución no fue homogénea entre jurisdicciones: provincias como Corrientes (99.8%), La Pampa (95.3%) y Neuquén (92.3%) concentraron casi la totalidad de su atención en el sector público, mientras que CABA presentó la mayor participación privada del país (56%).

A nivel provincial, Buenos Aires y CABA concentraron el 54.7% de los internados del país, con 75.046 y 54.105 casos respectivamente. Le siguieron Córdoba (18.875), Neuquén (12.049) y Santa Fe (9.491). Esta concentración territorial es relevante para interpretar los resultados del clustering y del modelo supervisado, dado que las provincias más grandes tienen mayor peso estadístico en los indicadores nacionales.

5.3. Clustering:

Para el análisis de clustering se evaluaron dos algoritmos de forma comparativa (KMeans y Clustering Jerárquico Aglomerativo con enlace de Ward) sobre tres segmentaciones: por provincia, por sector y por provincia×sector. Las variables de entrada fueron estandarizadas mediante StandardScaler e incorporan tanto indicadores de mortalidad y severidad como tiempos de respuesta del sistema y, como novedad respecto a la versión anterior, la proporción de casos atendidos durante períodos de alta y baja intensidad epidémica. Esta última variable permite que el clustering capture no solo el desempeño clínico sino también la exposición diferencial de cada jurisdicción a la presión asistencial.

El número óptimo de clusters se determinó mediante el método del codo y el Silhouette Score. Si bien el Silhouette recomendaba k=2 para la segmentación provincial (resultado que en la versión anterior aislaba únicamente a Formosa sin generar grupos analíticamente útiles para el resto del país) se tomó la decisión metodológica justificada de fijar k=3, obteniendo así perfiles de alto, medio y bajo desempeño interpretables. Ambos algoritmos produjeron resultados idénticos para la segmentación provincial (Silhouette=0.247), mientras que para provincia×sector el jerárquico superó levemente al KMeans (0.259 vs 0.176), siendo seleccionado como algoritmo final en esa segmentación.

La segmentación por provincia identificó tres perfiles claramente diferenciados. El Cluster 1 — "Mejor desempeño relativo" agrupa a CABA, Neuquén y Río Negro, con una mortalidad media del 18.4%, tasa de UCI del 11.6% y la mayor proporción de casos en períodos de baja intensidad (10.5%). Son las jurisdicciones que combinaron buenos resultados clínicos con menor exposición a los picos de demanda. El Cluster 0 — "Desempeño intermedio" concentra las 18 provincias restantes — entre ellas Buenos Aires, Córdoba, Santa Fe, Mendoza y Chaco — con una mortalidad media del 34.6%, UCI del 30.7% y la mayor exposición a períodos de alta intensidad (31.1% de sus casos). El Cluster 2 — "Caso atípico crítico" está compuesto exclusivamente por Formosa, con una mortalidad del 74%, UCI del 72.5% y una concentración del 49.2% de sus casos en períodos de alta intensidad, el valor más alto del país.

La incorporación de la intensidad epidémica como variable de clustering aportó una dimensión interpretativa relevante: el Cluster 1 de mejor desempeño no solo tiene menor mortalidad sino que operó mayoritariamente fuera de los picos, mientras que el Cluster 0 absorbió el grueso de la presión asistencial durante los meses críticos de 2021. Esto sugiere que parte de las diferencias de mortalidad entre jurisdicciones puede explicarse por la desigual distribución temporal de la carga, y no únicamente por capacidades estructurales del sistema hospitalario.

5.4. Modelo supervisado global

Para el análisis de modelado supervisado se evaluaron cuatro enfoques con el objetivo de explicar la variación en la tasa de mortalidad hospitalaria por provincia y período: Regresión Lineal, Ridge, Random Forest y XGBoost. Todos fueron comparados contra un baseline que predice siempre la media nacional (33.81%), con $R^2=0$ y RMSE=16.94% por definición. Todo modelo que no supere ese umbral carece de valor explicativo.
La validación se realizó mediante K-Fold con 5 particiones, respetando la dependencia temporal entre observaciones. Los resultados fueron los siguientes:

Modelo	R^2 medio	RMSE medio
Baseline	0.00	16.94%
Regresión Lineal	0.69	9.33%

Random Forest	0.68	9.51%
XGBoost	0.72	8.89%
Ridge (α=1.0)	0.69	9.33%

XGBoost fue seleccionado como modelo final por presentar el mayor R^2 (0.72) y el menor RMSE (8.89%), explicando el 72% de la variación en mortalidad entre provincias y períodos. Vale destacar que Regresión Lineal y Ridge obtuvieron resultados muy similares (R^2=0.69), lo que indica que el fenómeno tiene una componente lineal fuerte y que la complejidad adicional de XGBoost aporta una mejora marginal en términos explicativos.

En cuanto a las variables con mayor poder explicativo, el análisis de importancia por permutación identificó como factores determinantes la tasa de ARM (0.24), la edad mediana de los pacientes atendidos (0.17), la provincia (0.15), la severidad media (0.13) y la proporción de mayores de 60 años (0.11). La presencia de la provincia en tercer lugar confirma que el territorio tiene peso explicativo propio, más allá de las características clínicas y demográficas de los pacientes.

Sin embargo, el análisis de residuos por provincia matiza esta lectura. Una vez controlados edad, severidad, sector e intensidad epidémica, las diferencias territoriales se reducen a un rango de apenas 2.36 puntos porcentuales, sin ninguna provincia con exceso de mortalidad superior a 1.5pp y solo una con mejor desempeño por debajo de -1.5pp. Esto lleva a confirmar H5 de forma parcial: las diferencias sistemáticas entre provincias existen y son estadísticamente detectables, pero son considerablemente más pequeñas de lo que sugería el análisis descriptivo bruto. En otras palabras, la mayor parte de la variación en mortalidad entre jurisdicciones se explica por las características de los pacientes atendidos (edad y severidad) y no por diferencias estructurales del sistema hospitalario en sí. Este es en sí mismo un hallazgo relevante: sugiere que el sistema hospitalario argentino operó de forma relativamente homogénea en su respuesta una vez igualadas las condiciones clínicas de los pacientes.

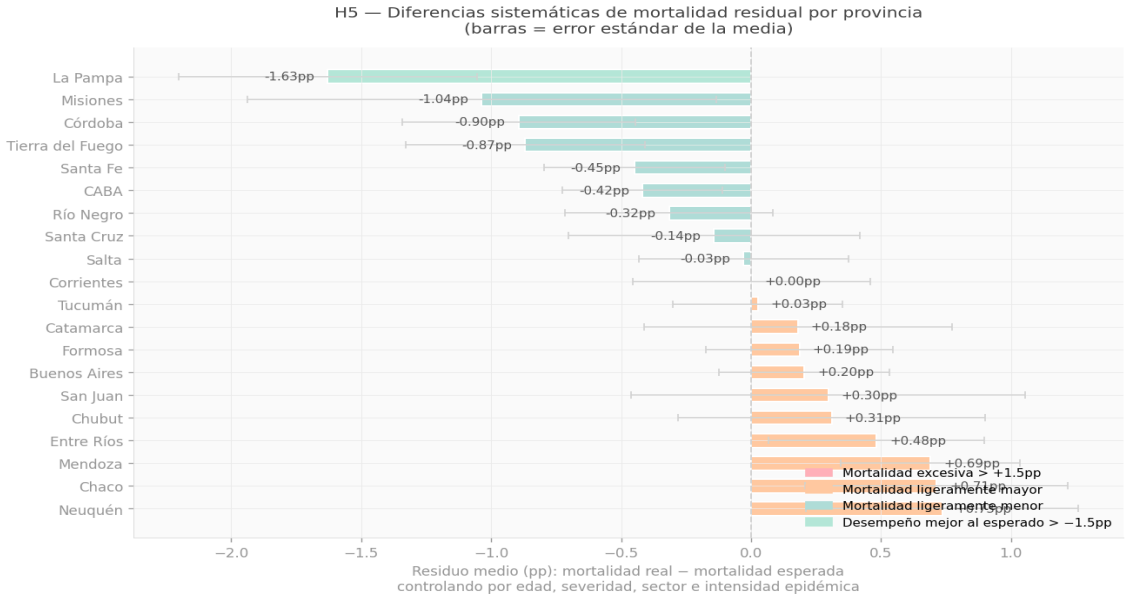

5.5. Modelos segmentados: público vs privado

El análisis comparativo entre el sector público y privado se abordó desde tres dimensiones complementarias: comparación descriptiva de KPIs, ajuste por composición etaria y análisis de residuos del modelo supervisado.

A nivel descriptivo, el sector público atendió el 65% de los internados (153.990 pacientes) frente al 35% del sector privado (82.866 pacientes), con una mortalidad bruta del 32.8% y 35.7% respectivamente. Esta diferencia inicial sugeriría un mejor desempeño del sector público, sin embargo el análisis de ajuste por edad revela una lectura opuesta. El sector público atiende una proporción significativamente mayor de pacientes jóvenes (42% de adultos jóvenes (31-60 años) vs 33.4% en el privado) mientras que el sector privado concentra más pacientes mayores, con un 16.2% de adultos mayores (81-90 años) vs 9.2% en el público y un 6% de ancianos vs 2.7%. Al estandarizar por edad, la mortalidad del sector público sube al 35.1% y la del privado baja al 31.1%, invirtiendo completamente la brecha. El efecto atribuible al perfil etario diferencial entre sectores es de 6.87 puntos porcentuales, lo que indica que la ventaja del sector público en mortalidad bruta se explica en gran medida por atender pacientes más jóvenes y no por una diferencia estructural en la calidad de atención.

Este hallazgo se refuerza al analizar la mortalidad por rango etario dentro de cada sector. En prácticamente todos los grupos etarios el sector público presenta mayor mortalidad que el

privado, siendo la brecha más pronunciada en adultos jóvenes (31-60 años): 21.2% en el público vs 13.9% en el privado, una diferencia de 7.3 puntos porcentuales. En los grupos de mayor edad la brecha se reduce considerablemente (adultos mayores 61.4% vs 59.9%, ancianos 67.6% vs 67.4%) lo que sugiere que ante casos de máxima severidad ambos sectores convergen en sus resultados.

Finalmente, el modelo XGBoost confirma que estas diferencias, si bien reales, son moderadas una vez controladas todas las variables. Los residuos por sector arrojaron -0.10pp para el privado y +0.05pp para el público respecto a la mortalidad esperada, diferencias estadísticamente presentes pero sanitariamente pequeñas. En conjunto, la evidencia sugiere que la brecha entre sectores responde principalmente a diferencias en el perfil de los pacientes atendidos y no a diferencias estructurales en la capacidad de respuesta hospitalaria, aunque la mayor mortalidad ajustada del sector público en grupos etarios intermedios merece seguimiento específico.

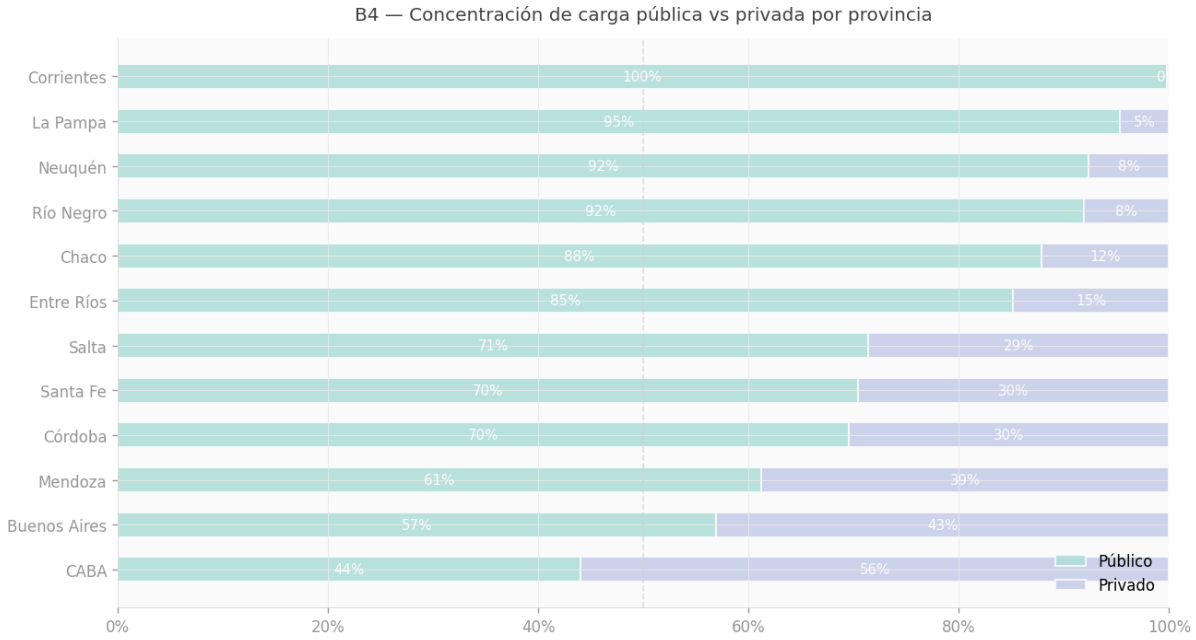

5.6. Modelos segmentados: Dinámica temporal

El análisis temporal confirma la hipótesis H3. La intensidad epidémica se clasificó en tres categorías usando umbrales estadísticos: solo 3 meses fueron de Alta intensidad (abril, mayo y junio de 2021, con mortalidades superiores al 43%), 6 meses de Baja intensidad y 19 de

Media. Mayo de 2021 fue el mes más crítico, concentrando 25.250 internaciones y una mortalidad del 46,1%. Durante ese pico el sector público absorbió el 72,2% de los casos, por encima de su promedio histórico del 64,6%, evidenciando que la presión asistencial recayó desproporcionadamente sobre el sistema público.

La composición etaria varió entre olas: los adultos jóvenes (31-60 años) pasaron del 40,3% en 2020 al 21,7% en 2022, mientras que los adultos mayores crecieron del 10,8% al 19,5%, patrón consistente con la inmunidad adquirida en grupos intermedios tras sucesivas olas y vacunación. La tasa de escalada a UCI superó el umbral de tensión en cuatro meses durante 2021, representando los escenarios de mayor presión combinada sobre recursos críticos.

La intensidad epidémica fue incorporada como variable tanto en el clustering como en el modelo XGBoost. Su inclusión reveló que el Cluster de mejor desempeño (CABA, Neuquén, Río Negro) no solo tuvo menor mortalidad sino que operó mayoritariamente fuera de los picos (10,5% de sus casos en alta intensidad vs. 31,1% del cluster intermedio), sugiriendo que parte de las diferencias territoriales de mortalidad se explica por la desigual distribución de la carga durante los picos y no únicamente por capacidades estructurales del sistema.

6. Conclusión

El presente proyecto analizó 236.856 registros de pacientes hospitalizados por COVID-19 en Argentina entre marzo de 2020 y junio de 2022, provenientes de los registros oficiales del SISA. A partir de un pipeline de datos que reduce el dataset original de 29,9 millones de registros a los casos con internación confirmada, se construyó un marco analítico integrado que combina análisis descriptivo, clustering no supervisado y modelado supervisado con XGBoost. La tasa de mortalidad hospitalaria global fue del 33,8%, un indicador que refleja la letalidad dentro del sistema hospitalario y que constituye el KPI central del proyecto: no mide cuántas personas murieron de COVID-19 en la población general, sino cuántas de las que llegaron al hospital no sobrevivieron.

El análisis de clustering identificó tres perfiles estructurales de desempeño hospitalario. El Cluster 1, integrado por CABA, Neuquén y Río Negro, presentó la menor mortalidad media del país (18,4%) y operó mayoritariamente fuera de los períodos de alta intensidad epidémica (solo el 13,6% de sus casos). El Cluster 0, que agrupa a las 18 provincias restantes

incluyendo Buenos Aires, Córdoba y Santa Fe, mostró una mortalidad media del 34,6% y absorbió el 31,1% de sus casos durante períodos de alta intensidad. Formosa conforma el Cluster 2 de forma exclusiva, con una mortalidad del 74,0% y el 49,2% de sus casos concentrados en los picos, constituyéndose en un caso atípico que el algoritmo aisló por su perfil radicalmente distinto al resto del país.

El modelado supervisado con XGBoost (R^2=0,720 en validación cruzada k=5) confirmó parcialmente la hipótesis H4: las diferencias sistemáticas de mortalidad entre provincias existen y son estadísticamente detectables, pero se reducen a un rango de apenas 2,4 puntos porcentuales una vez controladas edad, severidad, sector e intensidad epidémica. Este es en sí mismo un hallazgo relevante: sugiere que el sistema hospitalario argentino operó de forma relativamente homogénea una vez igualadas las condiciones de los pacientes, y que la mayor parte de la variación bruta en mortalidad entre jurisdicciones se explica por diferencias en el perfil demográfico y de severidad de los pacientes atendidos. Las variables con mayor poder explicativo fueron la tasa de ARM (0,24), la edad mediana (0,17), la provincia (0,15), la severidad media (0,13) y la proporción de mayores de 60 años (0,11).

El análisis sectorial reveló que la brecha bruta de mortalidad entre sector público (32,8%) y privado (35,7%) se invierte al ajustar por edad: la mortalidad estandarizada del público sube a 35,1% y la del privado baja a 31,1%, con un efecto atribuible al perfil etario de 6,87 puntos porcentuales. La brecha más pronunciada aparece en el grupo de Adultos Jóvenes (31–60 años), donde el sector público registra 21,2% frente al 13,9% del privado, diferencia que merece seguimiento específico. En conjunto, la evidencia sugiere que las diferencias entre sectores responden principalmente a variaciones en el perfil de los pacientes atendidos y no a diferencias estructurales en la calidad de la atención hospitalaria.

La cuantificación del valor de negocio estima 13.853 vidas evitables si las provincias de bajo desempeño hubieran operado al nivel del cluster de mejor desempeño. Las provincias con mayor potencial de mejora son Buenos Aires (9.785 vidas, brecha +13,0pp), Santa Fe (1.514 vidas, +11,2pp) y Formosa (745 vidas, +41,7pp). La simulación de escenarios proyecta que ante una nueva variante con perfil similar al pico histórico de mayo de 2021, el sistema enfrentaría aproximadamente 75.750 internaciones y 34.884 fallecidos en 3 meses (Escenario A). Una mejora del 20% en la respuesta institucional evitaría 6.977 muertes adicionales y liberaría 3.809 camas de UCI (Escenario C).

Como líneas de trabajo futuro se recomienda incorporar datos de comorbilidades clínicas para reducir el sesgo de confusión residual, extender el benchmarking a nuevas olas con datos actualizados del SISA, y desarrollar un sistema de alertas tempranas basado en los umbrales identificados (mortalidad mensual > 40,2% o tasa de escalada UCI > 26,1%). El marco analítico desarrollado es reproducible, documentado y de código abierto, constituyendo un insumo directo para la planificación estratégica del Ministerio de Salud ante futuros eventos epidémicos.

7. Bibliografía

- Grupo 7 — Diplomatura en Ciencia de Datos y Análisis Avanzado, UTN BA. (2025). covid-desempeño-sanitario: Análisis de desempeño sanitario del sistema hospitalario argentino durante la pandemia de COVID-19 [Repositorio de GitHub]. Recuperado de: https://github.com/Sebasvera1475/Analisis_de_Desempeno_Sanitario_COVID19_en_Argentina.git
- Grupo 7. *covid_internados (versión filtrada, depurada y transformada a partir de datos oficiales)* [dataset]. 2026. Basado en: Dirección Nacional de Epidemiología y Análisis de la Situación de Salud, Ministerio de Salud de la Nación. COVID-19: Casos registrados en la República Argentina. Disponible en: https://drive.google.com/file/d/1wTv6yeMsqVeuErM9lSkBNio-SIqoLRyj/view?usp=drive_link
- Dirección Nacional de Epidemiología y Análisis de la Situación de Salud, Ministerio de Salud de la Nación. COVID-19: Casos registrados en la República Argentina [dataset]. Datos Argentina; 20 de mayo de 2020. Archivo histórico de casos COVID-19 (01/03/2020–04/06/2022). Disponible en: https://datos.gob.ar/dataset/salud-covid-19-casos-registrados-republica-argentina/archivo/salud_fd657d02-a33a-498b-a91b-2ef1a68b8d16
- Diplomatura en Ciencia de Datos y Análisis Avanzado, UTN BA. (2025). Grupo 7 - Proyecto Covid-19 [Notebook de Google Colaboratory]. Recuperado de: https://drive.google.com/file/d/1MJ_armk8ekLB8RugYu9drXhuyrifTiPK/view?usp=drive_link